



Uniwersytet Ekonomiczny
we Wrocławiu

Projekt zaliczeniowy

*Przegląd literatury naukowej z wykorzystaniem
narzędzi data science*

Studia podyplomowe: Data Science: poziom podstawowy

Autor: Grzegorz Kulczycki

Wrocław, 2024

Streszczenie

W projekcie przedstawiono możliwości wykorzystania narzędzi data science do bibliometrycznego przeglądu literatury naukowej. Do analizy wykorzystano dwie bazy danych **Google Scholar** oraz **Semantic Scholar**. Wykonane analizy potwierdzają dużą skuteczność i użyteczność zastosowanych narzędzi data science. Narzędzia te w istotny sposób przyspieszają i zwiększają efektywność przeprowadzenia przeglądu literatury naukowej w porównaniu z tradycyjnymi metodami ich wykonywania.

Podziękowania

Składam serdeczne podziękowania dla **mgr Agnieszki Rosa** za zaangażowanie i merytoryczną pomoc.

Spis treści

Streszczenie	2
Spis treści	4
1 Wstęp i cel badań	5
2 Opis problemu badań	6
3 Metody badań	24
3.1 Narzędzia Data Science wykorzystane w pracy	24
3.2 Wybór baz danych indeksujących publikacje naukowe	28
4 Wyniki badań i analiz	29
4.1 Baza danych Google Scholar (GS)	29
4.2 Baza danych Semantic Scholar (SS)	48
5 Wnioski	53
6 Literatura	54

1 Wstęp i cel badań

Praca naukowa to określony rodzaj formy pracy twórczej związany z obiektywnym poznaniem zjawisk, rzeczy oraz różnego rodzaju relacji pomiędzy nimi. Wyniki prac naukowych przedstawia się w różnych formach (książki, raporty, czy sprawozdania) spośród których, najbardziej popularną metodą jest pisanie artykułów (publikacji) naukowych.

Publikację naukową można zdefiniować w różny sposób w zależności od celu w jakim została stworzona. Najogólniej publikacją naukową określa się doniesienie o uzyskanych wynikach badań lub opis istniejącego stanu wiedzy z określonego obszaru nauki. Artykuły naukowe zamieszczane są w czasopismach, które publikują je w formie papierowej lub najczęściej elektronicznej przez wydawnictwa naukowe. Ocena wpływu danych czasopism odbywa się poprzez analizę bibliometryczną cytowań, gdzie liczba cytowań artykułów w czasopiśmie stanowi miarę popularności i wpływu czasopisma. Większość wydawnictw publikujących prace naukowe wykorzystuje własne strony internetowe do przyjmowania, recenzowania oraz udostępniania publikowanych prac w trybie on-line.

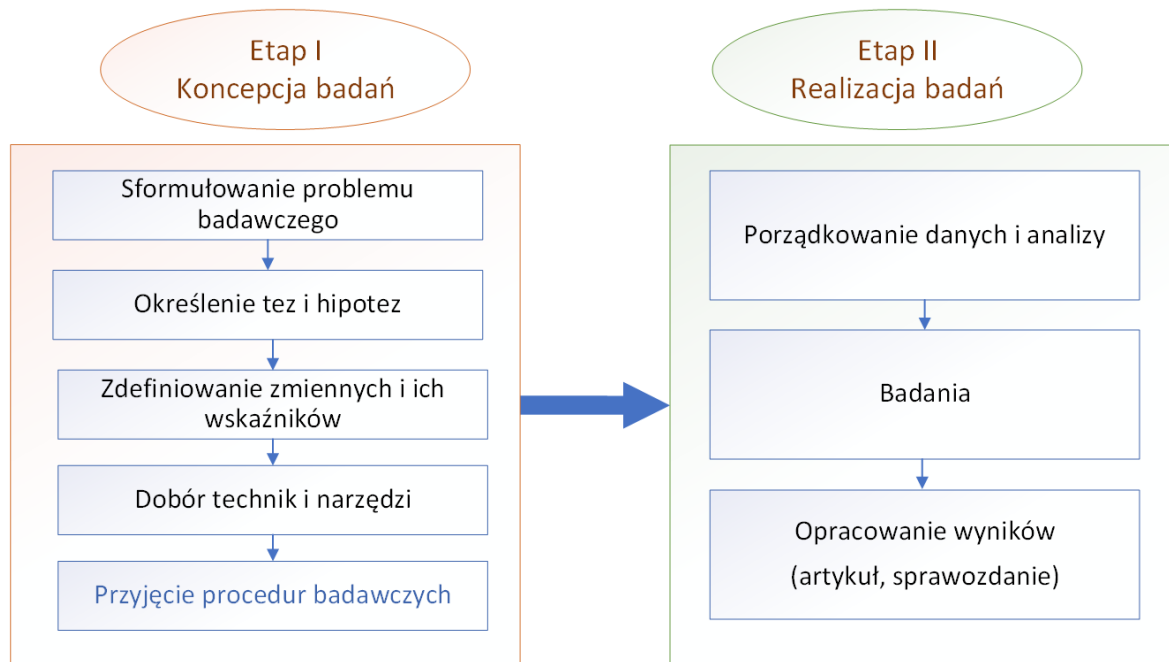
Naukowcy także podlegają ewaluacji między innymi poprzez systematyczną ocenę ich dorobku naukowego. Dorobek ten wyceniany jest między innymi w oparciu o opublikowane artykuły naukowe w czasopismach oraz ilość cytowań, jakie ten artykuł otrzymał. Ilość i jakość opublikowanych prac naukowych jest istotna dla pracowników jak i dla instytucji naukowych w której są zatrudnieni, ponieważ zarówno te podmioty jak również pracownicy w nich zatrudnieni podlegają okresowej ocenie. Ewaluację przeprowadza się za okres 4 lat poprzedzających rok jej przeprowadzenia, z uwzględnieniem osiągnięć naukowych pracowników (Dz. U., 2019). W związku z powyższym obserwuje się ścisłe wzajemne relacje pomiędzy naukowcami a wydawnictwami czasopism. Przyczynia się to do powstania dużej ilości artykułów naukowych, które są indeksowane w tematycznych bazach danych.

Cel badań: znaczący przyrost ilości artykułów w danych dyscyplinach naukowych nasila problemy z ich przeglądem i oceną. Wykonywanie takich przeglądów standardowymi "ręcznymi" metodami jest coraz bardziej czasochłonne i mało efektywne. Celem badań było wykonanie przeglądu bibliograficznego literatury naukowej metodami opartymi o narzędzia data science. Hipoteza badawcza projektu zakłada, że metody data science przyspieszają i zwiększając efektywność przeprowadzenia przeglądu bibliograficznego w porównaniu z tradycyjnymi metodami jego wykonania.

2 Opis problemu badań


Organizacja i etapy badań naukowych

Podczas prowadzenia badań naukowych wyróżnia się szereg etapów, które stanowią określoną logiczną procedurę badawczą. Etapy te należy traktować jako elastyczne elementy postępowania badawczego, jednak układ ich powinien być zawsze ścisły i racjonalny 2.1(modyfikacja własna za (Apanowicz, 2005)).



Rysunek 2.1: Etapy i czynności badań naukowych

Efektem udokumentowania przeprowadzonych badań najczęściej jest napisanie artykułu naukowego. Uniwersalny schemat często wykorzystywany podczas realizacji publikacji naukowej przedstawiono na rysunku 2.2.



Rysunek 2.2: Uniwersalna struktura publikacji naukowej

Po ustaleniu problemu badawczego i tematu pracy, rozpoczyna się zwykle etap pracy związany z poszukiwaniem literatury przedmiotu. Celem tego etapu pracy jest stwierdzenie stanu wiedzy przeszłej i aktualnej związanej z podjętym tematem badań, określenie brakujących luk i możliwości ich wypełnienia oraz zasadności poszerzenia wiedzy z danego obszaru badań (Cooper, 1986) .

Przegląd literatury dotyczy najczęściej publikacji naukowych, które w obowiązującym obecnie prawie (Dz. U., 2019) w rozumieniu ewaluacji (PBN, 2020) określane są jako: - artykuł naukowy, - monografię naukową, - rozdział w monografii naukowej.

Słownik Polskiej Bibliografii Naukowej (PBN, 2020) podaje następujące definicje publikacji naukowych:

1. **Artykuł naukowy** jest to recenzowany artykuł opublikowany w czasopiśmie naukowym albo w recenzowanych materiałach z międzynarodowych konferencji naukowych:

- przedstawiający określone zagadnienie naukowe w sposób oryginalny i twórczy, problemowy albo przekrojowy;
- opatrzone przypisami, bibliografią lub innym właściwym dla danej dyscypliny naukowej aparatem naukowym.

Artykułem naukowym jest również artykuł recenzyjny opublikowany w czasopiśmie naukowym zamieszczonym w wykazie czasopism.

Artykułem naukowym nie jest: edytorial, abstrakt, rozszerzony abstrakt, list, errata oraz nota redakcyjna.

2. **Monografia naukowa** jest to recenzowana publikacja książkowa:

- przedstawiająca określone zagadnienie naukowe w sposób oryginalny i twórczy;
- opatrzone przypisami, bibliografią lub innym właściwym dla danej dyscypliny naukowej aparatem naukowym.

Monografią naukową jest również:

- recenzowany i opatrzone przypisami, bibliografią lub innym właściwym dla danej dyscypliny naukowej aparatem naukowym przekład na język polski dzieła istotnego dla nauki lub kultury albo na inny język nowożytny dzieła istotnego dla nauki lub kultury, wydane w języku polskim;
- edycja naukowa tekstów źródłowych.


Oceny poziomu naukowego prowadzonej działalności naukowej w zakresie badań naukowych i prac rozwojowych dokonuje się z uwzględnieniem następujących rodzajów osiągnięć naukowych ([Dz. U., 2019](#)):

1. artykułów naukowych opublikowanych w czasopismach naukowych i w recenzowanych materiałach z międzynarodowych konferencji naukowych, zamieszczonych w wykazie tych czasopism i materiałów sporządzonym zgodnie z przepisami wydanymi na podstawie art. 267 ust. 2 pkt 2 ustawy, zwanym dalej „wykazem czasopism”;

2. artykułów naukowych opublikowanych w czasopismach naukowych niezamieszczonych w wykazie czasopism;
3. monografii naukowych wydanych przez wydawnictwa zamieszczone w wykazie tych wydawnictw sporządzonym zgodnie z przepisami wydanymi na podstawie art. 267 ust. 2 pkt 2 ustawy, zwanym dalej „wykazem wydawnictw”;
4. monografii naukowych wydanych przez wydawnictwa niezamieszczone w wykazie wydawnictw, redakcji naukowych takich monografii i autorstwa rozdziałów w takich monografiach;
5. przyznanych patentów na wynalazki, praw ochronnych na wzory użytkowe i wyłącznych praw hodowców do odmian roślin.

Proces publikowania wyników badań obecnie ulega ciągłej modyfikacji i przyspieszeniu związanym z coraz większym dostępem do Internetu oraz szybszemu procesowi przyjmowania i recenzji publikacji poprzez strony własne Wydawnictw.

Szacuje się, że od 1996 roku opublikowano co najmniej 64 miliony artykułów naukowych, a tempo wzrostu liczby nowo opublikowanych artykułów ciągle ma tendencje wzrostową (rys. 2.3) (Curcic, 2023).




Rysunek 2.3: Ilość publikowanych artykułów rocznie na świecie

Z raportu [S&E - Science and Engineering Indicators](#) wynika, że roczny przyrost ilości publikacji na świecie artykułów naukowo-technicznych wyniósł 4% w latach 2010-2020 ([Curcic, 2023](#)). Na rysunku 2.4 zestawiono ilość artykułów naukowo-technicznych opublikowanych ze wszystkich obszarów nauki na świecie oraz w 15 największych krajach w latach 2010 i 2020.

Rank	Region, country, or economy	2010	2020	2020 world total (%)
na	World	1,938,121	2,940,807	na
1	China	308,769	669,744	22.77
2	United States	409,512	455,856	15.50
3	India	60,555	149,213	5.07
4	Germany	97,255	109,379	3.72
5	United Kingdom	94,081	105,564	3.59
6	Japan	108,534	101,014	3.43
7	Russia	33,855	89,967	3.06
8	Italy	58,252	85,419	2.90
9	South Korea	50,224	72,490	2.46
10	Brazil	41,501	70,292	2.39
11	France	68,300	66,479	2.26
12	Canada	56,445	65,822	2.24
13	Spain	49,031	65,638	2.23
14	Australia	41,661	60,891	2.07
15	Iran	24,694	57,755	1.96


Rysunek 2.4: Ilość opublikowanych artykułów naukowo-technicznych

Graficzny obraz przyrostu publikowanych artykułów naukowo-technicznych od roku 1996 przedstawiono na rysunku 2.5. Uwidacznia się na nim wyraźna ogólna tendencja przyrostu publikacji na świecie, a z pośród analizowanych krajów szczególnie jest to widoczne w Chinach.




Rysunek 2.5: Trendy w ilości publikowanych artykułów naukowo-technicznych

Ilość publikowanych artykułów na świecie koreluje dodatnio ze wzrastającą ilością czasopism akademickich. W 2020 roku odnotowano 46,7 tys. czasopism, a ciągu ostatnich 10 lat liczba ich wzrosła o 29% (rys. 2.6) (Curcic, 2023).




Rysunek 2.6: Ilość czasopism akademickich na świecie

O wymiarze publikowanych prac naukowych na świecie z zakresu nauk fizycznych, chemicznych oraz nauk o życiu i środowisku można się dowiedzieć ze strony [natureindex.com](https://www.natureindex.com). Na podstawie danych (od 1 czerwca 2021 do 31 maja 2022) z tej strony na rysunku 2.7 wyszczególniono kraje o największej ilości publikacji. Dane te uwidaczniają, że niekwestionowanymi liderami w tych obszarach badań są USA oraz Chiny.



Rysunek 2.7: Kraje o największej ilości publikacji z analizowanego obszaru badań.

Ilość prac naukowych z tych obszarów badawczych w Europie przedstawiono na rysunku 2.8, gdzie uwidacznia się, że na kontynencie europejskim liderami są Wielka Brytania i Niemcy.



Rysunek 2.8: Ilość publikacji w Europie z analizowanego obszaru badań.

W Polsce opublikowano w tym okresie z tego obszaru badań 906 artykułów naukowych z pośród których 296 były napisane ze współautorami z innych krajów. Udział publikacji w poszczególnych obszarach badań przedstawiono na rysunku [2.9](#).

Subject	Count	Share
 Physical Sciences	520	133.98
 Earth & Environmental Sciences	50	13.23
 Life Sciences	164	42.12
 Chemistry	234	120.64

Outputs by subject

Rysunek 2.9: Ilość publikacji w zależności od obszaru badań.

W latach 2017–2021 opublikowano w Polsce około 619 tys. prac naukowych, z których większość (67%) stanowiły artykuły, 29% – rozdziały w monografiach, a pozostałe 4% – monografie naukowe (PWN, 2023).

Tak znaczący przyrost ilości artykułów naukowych nasilają problemy z ich przeglądem i oceną, która ma na celu znalezienie pytań bez odpowiedzi lub nierozwiązanych problemów w danej dziedzinie.

W pracy naukowej wykonywane są różnego rodzaju przeglądy literatury w zależności od celu ich wykonania (Chigbu i in., 2023). Zestawienie rodzajów przeglądów literatury przedstawiono na rysunku 2.10.

Rodzaje przeglądów	Cel przeglądu
Tradycyjny przegląd literatury	Ustanawia ramy teoretyczne lub koncentruje się na badaniach kontekście pisania publikacji.
Przegląd systematyczny	Rygorystycznie analizuje dane i wyniki innych naukowców, aby odpowiedzieć na konkretne pytania badawcze. Ten typ przeglądu jest wysoce rygorystyczny, ponieważ materiały (i sposób ich pozyskiwania) są ograniczone procedurami.
Przegląd integracyjny	Buduje nową wiedzę w oparciu o istniejącą literaturę zgodnie z racjonalistyczną perspektywą.
Przegląd zakresowy	Podobny do systematycznego przeglądu literatury. Różnica polega na tym, że nie ma ograniczeń co do pozyskiwanych materiałów.
Przegląd interpretacyjny	Interpretuje to, co napisali inni badacze, aby przedstawić konkretne perspektywy.
Przegląd iteracyjny	Podejście oparte na algorytmie, którego celem jest zestawienie wszystkich badań w określonej dziedzinie.
Meta-analiza	Wykrywa wzorce argumentacji i wyciąga bezpośrednie wnioski z opublikowanych prac.
Meta-synteza	Ocenia i analizuje wyniki badań jakościowych, w celu wyjaśniania określonych pojęć
Przegląd bibliometryczny	Ocenia literaturę w systematyczny sposób poprzez pomiar (ilościowy) określonych wskaźników. Oceniani są autorzy, cytowania, czasopisma, kraje i lata publikacji, a także zastosowana metodologia.

Rysunek 2.10: Rodzaje przeglądów literatury

Bazy danych indeksujące publikacje naukowe

Odpowiedzią na te wyzwania jest powstanie baz danych indeksujące istniejące zasoby prac naukowych oraz ich twórców. Wprowadzono w nich różne wskaźniki oceniające siłę oddziaływania danej publikacji (cytowania) oraz oceniające także naukowców (np. wskaźnik Hirscha h-index).


Obecnie na świecie istnieje znaczna liczba baz danych bibliograficznych. Szacuje się jednak, że istnieje tysiące bibliograficznych baz danych dostępnych na całym świecie, obejmujących różne obszary tematyczne, takie jak medycyna, nauki ścisłe, nauki humanistyczne, nauki społeczne itp. Nie jest możliwe zestawienie kompletnej listy takich baz, ponieważ nowe są stale tworzone, podczas gdy inne mogą stać się przestarzałe lub połączone w większe bazy danych.

Z zestawieniem wybranych i polecanych akademickich baz danych i wyszukiwarek zapoznać się można na stronie [Wikipedii](#). Z tego zestawienia subiektywnie wybrano i scharakteryzowano poniżej kilka baz danych.

Pracownicy nauki korzystają najczęściej z baz danych, takich jak Google Scholar, Semantic Scholar, Lens, Scopus, Web of Science i ResearchGate w celu uzyskania dostępu i oceny literatury naukowej. Pomiędzy tymi bazami zauważa się pewne podobieństwa istnieją jednak również istotne różnice pod względem ich zasięgu, zakresu, możliwości wyszukiwania i wskaźników cytowań.

2.0.1 Charakterystyka wybranych baz indeksujących

- [Google Scholar](#) najpopularniejsze narzędzie ze względu na to, że jest szybkie, bezpłatne i wszechstronne. Usługę tę rozpoczęto w listopadzie 2004 r. Kataloguje piśmiennictwo akademickie z różnych dziedzin i źródeł, takich jak książki, prace dyplomowe, artykuły z czasopism, materiały konferencyjne i preprinty (rys. 2.11). Obejmuje ona szeroki zakres publikacji, w tym takie, które mogą nie być indeksowane przez inne bazy danych.




Stand on the shoulders of giants

Rysunek 2.11: Google Scholar


- [Semantic Scholar](#) baza oparta na metodach sztucznej inteligencji, która nadaje priorytet informatyce i badaniom biomedycznym (rys. 2.12). Indeksuje i kategoryzuje artykuły na podstawie ich treści, cytowań i autorów oraz oferuje czytelnikom

spersonalizowane rekomendacje na podstawie ich historii wyszukiwania. Semantic Scholar¹ (S2), został uruchomiony w 2015 r. przez [Allen Institute for Artificial Intelligence](#)² (AI2), aby pomóc naukowcom w walce z przeciążeniem informacyjnym oraz skuteczniejszym odkrywaniu i rozumieniu najistotniejszej literatury naukowej.



Rysunek 2.12: Platforma Semantic Scholar


Celem Otwartej Platformy Danych Semantic Scholar jest zbudowanie i rozpowszechnianie Akademickiego Grafu Semantic Scholar lub S2AG (wymawiane jako “stag”). S2AG to ujednoznaczony, wysokiej jakości bibliograficzny graf wiedzy. Węzły S2AG reprezentują artykuły, autorów, miejsca i instytucje akademickie. Krawędzie reprezentują artykuły napisane przez autora, artykuły cytowane przez inny artykuł, artykuły opublikowane w miejscu i autorów powiązanych z instytucją. S2AG jest tworzony poprzez wprowadzanie różnych źródeł danych do naszych danych i jest dystrybuowany za pośrednictwem różnych publicznie dostępnych interfejsów API i zbiorów danych, jak pokazano na rysunku 2.13 ([Kinney i in., 2023](#)).



Rysunek 2.13: Graf platformy Semantic Scholar


Firma planuje w niedalekiej przyszłości udostępnić wybrane funkcje semantyczne jako usługi, które użytkownicy będą mogli zastosować do własnych danych oraz ulepszyć istniejącą konstrukcję grafów wiedzy i modele cech semantycznych (Kinney i in., 2023).

- **Lens** darmowy i otwarty zasób służący do wyszukiwania, analizowania i zarządzania danymi patentowymi i naukowymi (rys. 2.14). Umożliwia użytkownikom wyszukiwanie i dostęp do ponad 200 milionów dokumentów patentowych i 100 milionów publikacji akademickich z różnych źródeł.



Rysunek 2.14: Lens

- **Scopus**: komercyjna baza danych, której właścicielem jest wydawnictwo Elsevier. Zawiera ona informacje o ponad 80 milionach artykułów z różnych dziedzin, w tym nauk społecznych, technologii i opieki zdrowotnej. Indeksuje książki, czasopisma, materiały konferencyjne, patenty i materiały konferencyjne oraz oferuje użytkownikom wskaźniki cytowań, takie jak indeks h, liczba cytowań i efekt cytowania określonych publikacji (rys. 2.15).



Rysunek 2.15: Scopus

Scopus to baza abstraktów i cytowań recenzowanej literatury, w tym czasopism naukowych, książek i materiałów konferencyjnych. Scopus zapewnia kompleksowy przegląd światowych wyników badań w dziedzinie nauk ścisłych, technologii, medycyny, nauk społecznych oraz sztuki i nauk humanistycznych.


- **Web of Science** komercyjna baza danych, której właścicielem jest Clarivate Analytics (rys. 2.16). Bazą danych cytowań typu for-profit, która zawiera informacje z zakresu nauk humanistycznych, społecznych i ścisłych. Baza danych zawiera recenzowane czasopisma, materiały konferencyjne, książki, patenty i inne publikacje naukowe, zapewniając użytkownikom dostęp do wiarygodnych i autorytatywnych informacji. Użytkownicy mogą przeglądać liczbę cytowań, indeksy h i inne wskaźniki, aby ocenić wpływ i znaczenie poszczególnych artykułów, autorów lub czasopism. Metodologia indeksowania tej bazy obejmuje proces selekcji treści, ekstrakcji metadanych, kontroli jakości oraz śledzenia cytowań i aktualizacji.

Web of Science platform



Rysunek 2.16: Zakres bazy tematycznej Web of Science

ResearchGate: ResearchGate to serwis społecznościowy, który umożliwia naukowcom współpracę ze sobą, dzielenie się swoją pracą i znajdowanie nowych badań (rys. 2.17). Ponadto oferuje użytkownikom wskaźniki cytowań, takie jak h-index, liczba cytowań i wynik RG, który jest określany na podstawie aktywności badawczej użytkownika na platformie.



Rysunek 2.17: ResearchGate

Zestawienie głównych dostawców danych naukowych w trzech kluczowych wymiarach: kompleksowości, dostępu i oferowanych usług przedstawiono na rysunku 2.18 (Kinney i in., 2023). Uwidaczniają się w tym zestawieniu duże różnice w podejściu do zakresu świadczonych usług oraz ich dostępności. Jeden z największych dostawców tych usług Google Scholar nie zapewnia oficjalnego dostępu API do ekstrakcji (skrobania) danych z bazy, natomiast Semantic Scholar zapewnia kompleksową i otwartą bazę wiedzy z najszerszym wachlarzem usług.

Resource	URL	Article Count	Access	Services
Aminer	aminer.org	321.5M	open	D*
arXiv	arxiv.org	2M	open	D**,F,S
BASE	base-search.net	180.5M	open	S
CORE	core.ac.uk	207.3M	open	D*, S
Dimensions	app.dimensions.ai	123.8M	subscription	D, F, M, S
Google Scholar	scholar.google.com	?	-	-
The Lens	lens.org	240.4M	subscription	D, M, S
Meta	-	-	terminated 3/31/22	-
Microsoft Academic	-	-	terminated 12/31/21	-
OpenAlex	openalex.org	205.2M	open	D, F, M
PubMed Central	ncbi.nlm.nih.gov/pmc/	7.5M	open	D**,F,P,S
ResearchGate	researchgate.net	135.0M	-	-
Scopus	scopus.com	84.0M	subscription	F, M, S
Semantic Scholar	semanticscholar.org	205M	open	D, F, M, P, S, T
Web of Science Core	webofknowledge.com	83.2M	subscription	F, M, S

Key: D=data download; F=field-of-study classification; M=advanced metadata;
P=semantically parsed text; S=title and abstract search; T=natural language summarization
*=data more than a year stale; **=restricted fields of study
Article count does not include patents or datasets.

Rysunek 2.18: Porównanie wiodących dostawców danych naukowych

Podsumowanie:

Na podstawie powyższego opisu uwidacznia się wyraźnie problem z wyszukaniem najlepiej powiązanych artykułów naukowych dla zakładanego tematu badań. Wykonywanie takich przeglądów standardowymi “ręcznymi” metodami jest bardzo czasochłonne i mało efektywne, dlatego metody i narzędzia data science umożliwiają ten etap pracy naukowej znacznie przyspieszyć i zwiększyć jego efektywność.

3 Metody badań

W pracy własnej wykorzystano narzędzia z obszaru dziedziny Data Science, dlatego poniżej zdefiniowano ten obszar wiedzy.

Data Science (polska nazwa - danologia) to interdyscyplinarna dziedzina generalnie zajmująca się analizą danych (pozyskiwaniem, eksploracją, wizualizowaniem i wyciąganiem z takich analiz wniosków. W szeroko rozumianym obszarze Data Science wykorzystuje się metody oparte na programowaniu, analizie statystycznej, analizie dużych baz danych (Big Data) oraz metody z zakresu sztucznej inteligencji, czyli uczenie maszynowe (Machine Learning), czy sieci neuronowe.

3.1 Narzędzia Data Science wykorzystane w pracy

- Język programowania Python
- Język programowania R
- Program LaTeX
- RStudio
- R Markdown
- Zotero menadżer bibliografii.

3.1.1 Język Python python.org

Python określany jest jako wysoko poziomowy, dynamiczny językiem ogólnego przeznaczenia (rys. 3.1).



Rysunek 3.1: Program Python

Obecnie jest najbardziej popularnym i najszybciej rozwijającym się językiem programowania na świecie według portalu [TIOBE Index](#) (rys. 3.2).

Feb 2024	Feb 2023	Change	Programming Language		Ratings	Change
1	1			Python	15.16%	-0.32%
2	2			C	10.97%	-4.41%
3	3			C++	10.53%	-3.40%
4	4			Java	8.88%	-4.33%
5	5			C#	7.53%	+1.15%
6	7	▲		JavaScript	3.17%	+0.64%
7	8	▲		SQL	1.82%	-0.30%
8	11	▲		Go	1.73%	+0.61%
9	6	▼		Visual Basic	1.52%	-2.62%
10	10			PHP	1.51%	+0.21%

Rysunek 3.2: Ranking programów TIOBE Index

Pierwsza wersja Pythona ukazała się na początku 1991 roku i zaliczany jest do kategorii oprogramowania Open Source. Do głównych zalet Pythona zalicza się nowoczesną składnię języka z opcją wyboru różnych paradygmatów programowania (funkcyjnego, obiektowego, reaktywnego), dużą i przyjazną społeczność, bogaty zbiór wbudowanych i przenośnych opcji, sprawną komunikację z innymi częściami aplikacji, współpracę pomiędzy najważniejszymi platformami - Windowsa oraz Linuxa ([Comarch, 2023](#)).

3.1.2 Język R [r-project.org](#)

R jest oprogramowaniem o otwartym kodzie źródłowym, dostępnym w Uniksie, Linuksie, a także systemach macOS i Windows ([Wickham i Grolemund, 2018](#)).

Logo tego programu przedstawiono na rysunku 3.3.



Rysunek 3.3: Logo programu R.

Język R jest językiem interpretowanym z elastyczną składnią i pozwala użytkownikom na definiowanie własnych, dowolnie złożonych, funkcji ([Górecki, 2011](#)).

R wykorzystuje się do obliczeń statystyczno-matematycznych, umożliwia on również tworzenie zaawansowanych wykresów.

Po zainstalowaniu podstawowego środowiska R mamy już dostęp do wielu użytecznych funkcjonalności, jednak możliwości pracy w R zwiększają się bardzo po zainstalowaniu dodatkowych pakietów (package). Szacuje się, że 2020 roku dostępnych ich było około 16 tysięcy [wikipedia.org](https://www.wikipedia.org).

3.1.3 RStudio rstudio.com


Istnieje kilka graficznych interfejsów dla programu R, wśród nich najbardziej popularnym jest RStudio (rys. 3.4).

RStudio określa się jako zintegrowane środowisko programistyczne (IDE) dla języka R.



Rysunek 3.4: Logo RStudio

RStudio zawiera konsolę, edytor podświetlający składnię i obsługuje bezpośrednie wykonywanie kodu, a także narzędzia do tworzenia wykresów, historii, debugowania i zarządzania przestrzenią roboczą (rys. 3.5).



Rysunek 3.5: RStudio

3.1.4 R Markdown rmarkdown.com

Rmarkdown to narzędzie do tworzenia dynamicznych dokumentów i zestawień. Język znaczników, którego celem jest jak największe uproszczenie tworzenia i formatowania tekstu wikipedia.org.



Rysunek 3.6: Rmarkdown

Biblioteka rmarkdown wraz z formatem R Markdown pozwala na przygotowanie estetycznie wyglądających raportów, a dokumenty otrzymywane w wyniku ich tworzenia są dynamiczne ponieważ istnieje w nich możliwość zagnieżdżania języka R (Struś, 2017).

3.1.5 LaTeX latex-project.org

LaTeX to oprogramowanie do zautomatyzowanego składu tekstu, a także związany z nim język znaczników, służący do formatowania dokumentów tekstowych i tekstowo-graficznych wikipedia.org.



Rysunek 3.7: LaTeX

Oprogramowanie to określane jest także jako zestaw makropoleceń stanowiących nadbudowę nad systemem składu TEX, automatyzujących wiele czynności związanych z procesem poprawnego składania tekstu ([Ziemkiewicz i Karłowska-Pik, 2013](#)).

3.2 Wybór baz danych indeksujących publikacje naukowe

Do badań własnych z zakresu przeglądu literatury naukowej wybrano dwie różniące się wieloma cechami bazy danych: **Google Scholar** oraz **Semantic Scholar**.

Przyjęto **metodę bibliometrycznego przeglądu literatury**, czyli oceniano literaturę w systematyczny sposób poprzez pomiar (ilościowy) określonych wskaźników dla autorów publikacji, ilości ich cytowań, rodzaju czasopism, czy lata publikacji).


W przeciwieństwie do przeglądów tradycyjnych, charakterystyką metody przeglądu bibliometrycznego jest to, że cały proces pozyskiwania, oceny i syntezy literatury powinien być dokładnie dokumentowany i przebiegać według ściśle określonych standardów ([Tranfield i in., 2003](#)).

4 Wyniki badań i analiz

4.1 Baza danych Google Scholar (GS)

Przeszukiwanie bazy w tradycyjny sposób odbywa się poprzez wyszukiwarke strony [Google Scholar](#).

```
library(webshot2)
webshot("https://scholar.google.com",
        "Rysunki/wyszykiwarka_google_scholar.png")
```



Przeszukiwanie zasobów GS różni się pod kilkoma względami od przeszukiwania innych baz. Baza ta posiada własną listę operatorów, które nie występują w żadnej innej bazie danych. Stosować można podczas wyszukiwania niektóre popularne operatory ograniczające lub rozszerzające wyszukiwanie (takie jak cudzysłów lub gwiazdka), natomiast z innych jak operatora wyszukiwania logicznego NOT nie można skorzystać. Google używa znaku minus zamiast powszechnie używanego terminu NOT. GS używają

niejawnego AND - a nie logicznego AND, czyli kiedy operator ten jest wprowadzane do zapytania wyszukiwania, Google traktuje je jako słowo w zapytaniu wyszukiwania i nie rozpoznaje go jako operatora wyszukiwania. GS ignoruje popularne słowa, takie jak a, and, the i tak dalej, z wyjątkiem gdy umieszczone są w cudzysłowie.

Wybrane operatory wyszukiwania Google Scholar:

publikacja: Wyniki będą zawierać tylko publikacje zawierające określone terminy. Na przykład wyszukiwanie “publication:computers in libraries” będzie zawierać tylko wyniki z publikacji Computers in Libraries.

autor: Lista wyników będzie zawierać tylko publikacje wskazanego autora, na przykład, autor: G Kulczycki

define: używany tylko w Google, gdy oczekuje się szybkich definicji, na przykład, “define:word”

cudzysłów (” “) używany do łączenia dokładnej frazy, może być również używany do zapewnienia, że określone słowo zostanie uwzględnione.

Uniwersalne operatory logiczne i logika wyszukiwania:

OR - znany również jako suma logiczna, operator OR “rozszerza wyszukiwanie poprzez uwzględnienie synonimów i powiązanych terminów w zapytaniu”

znak minus (-) główną funkcją znaku minus jest wykluczenie terminu, GS używa znaku minus zamiast powszechnie używanego terminu NOT.

gwiazdka (*) używana jako operator wieloznaczny

Przykład wyszukiwania w basie GS dla frazy “elemental sulphur fertilization” w wyniku wyszukiwania uzyskuje się 42 pozycje publikacji (rys. 4.1).

The screenshot shows the Google Scholar interface. At the top, the search bar contains the query "elemental sulphur fertilization". Below the search bar, the results are listed under the heading "Articles". The first result is titled "Sulphur as a fertiliser component determining crop yield and quality" by M Skwierawska, Z Benedycka, K Jankowski, et al., published in 2016. The second result is titled "[PDF] The effect of soil supplementation with nitrogen and elemental sulphur on chlorophyll content and grain yield of maize (Zea mays L.)" by P Szulc, J Bocianowski, et al., published in 2012. The third result is titled "The effect of sulphur fertilisation on yield and technological parameters of spring wheat grain" by P Ryant, L Hrivna, et al., published in 2004. On the left side, there are filters for "Any time", "Sort by relevance", "Any type", and checkboxes for "include patents", "include citations", and "Create alert".

Rysunek 4.1: Wyszukiwanie tradycyjne frazy słów w GS

Polityka firmy Google określa, że dostęp do zasobów GS powinien odbywać poprzez interfejs ich wyszukiwarki i instrukcji podanych przez firmę. GS nie zapewnia API (Application Programming Interface), a dostęp do zasobów jest wyszczególniony poprzez plik robot.txt (rys. 4.2).

```
User-agent: *
Disallow: /search
Disallow: /index.html
Disallow: /scholar
Disallow: /citations?
Allow: /citations?user=
Disallow: /citations?*cstart=
Disallow: /citations?user=%40
Disallow: /citations?user=%@
Allow: /citations?view_op=list_classic_articles
Allow: /citations?view_op=metrics_intro
Allow: /citations?view_op=new_profile
Allow: /citations?view_op=sitemap
Allow: /citations?view_op=top_venues

User-agent: Twitterbot
Disallow:

User-agent: facebookexternalhit
Disallow:

User-agent: PetalBot
Disallow: /
```

Rysunek 4.2: Wyszczególnienie zasad dostępu do zasobów GS

Baza Google Scholar zezwala na dostęp do:

- profili użytkowników: Allow: /citations?user=
(np. <https://scholar.google.pl/citations?user=RNDE9-wAAAAJ&hl>)
- zestawienia obszarów dziedzin badawczych: Allow: /citations?view_op=list_classic_articles
(np. https://scholar.google.com/citations?view_op=list_classic_articles&hl=en&by=2006)
- Zestawienia kategorii czasopism: Allow: /citations?view_op=metrics_intro
(np. https://scholar.google.com/citations?view_op=metrics_intro)

4.1.1 Wskaźniki bibliometryczne dla wybranych naukowców

W ramach dozwolonego przez GS dostępu do bazy przeprowadzono analizę wskaźników bibliometrycznych dla wybranych naukowców za pomocą biblioteki [scholar v. 0.2.4](#).

4.1.2 Zestawienie ilości opublikowanych artykułów dla kilku naukowców

Do analizy wybrano cztery profile naukowców, różniących się stażem pracy na Uczelni, żeby zobrazować intensywność i dynamikę ich potencjału publikacyjnego.

```
#wymagane biblioteki
library(scholar)
library(tidyverse)
library(ggplot2)


# id użytkowników
Kulczycki <- "RNDE9-wAAAAJ"
Sacala <- "jkj3pCQAAAAJ&hl"
Samoraj <- "um0TaCEAAAAJ"
Pietr <- "L6MYKCQAAAAJ&hl"

# Ile artykułów opublikowali?
Kulczycki.num <- get_num_articles(Kulczycki)
Sacala.num <- get_num_articles(Sacala)
Samoraj.num <- get_num_articles(Samoraj)
Pietr.num <- get_num_articles(Pietr)

# utworzenie ramki danych
num <- data.frame (Ilosc = c(Kulczycki.num,
                             Sacala.num,
                             Samoraj.num,
                             Pietr.num),
                  Osoba= c("Kulczycki", "Sacala", "Samoraj", "Pietr"))

# wizualizacja ilości cytowań
ggplot(num, aes(x=Osoba, y=Ilosc, fill = Osoba)) +
```

```
geom_col()+
theme_bw() +
scale_fill_brewer(palette = "BrBG")+
geom_text(aes(label=Ilosc),position=position_stack(vjust=1.1),size=6)+
theme(plot.title = element_text(size=14, hjust = 0.5),
      legend.position='none',
      axis.title.x=element_blank(),
      axis.text.x = element_text(face="bold", color="#993333", size=14),
      axis.text.y = element_text(size = 14),
      axis.title.y = element_text(size = 14))
```



Współpracę publikacyjną dla wybranego naukowca przedstawiono z wykorzystaniem biblioteki [scholarnetwork](#).

```
library(igraph)
library(scholarnetwork)
library(ggplot2)
```

```

d <- extractNetwork(id="RNDE9-wAAAAJ", n=2)
str(d)

## List of 2
## $ nodes:'data.frame':  53 obs. of  3 variables:
## ..$ label : chr [1:53] "A Bartmański" "A Bartmański" "A Demczuk" "A Jachymczak" ...
## ..$ degree: num [1:53] 0.667 0.667 5.45 2.667 2.833 ...
## ..$ group : num [1:53] 7 12 2 8 1 1 5 6 1 7 ...
## $ edges:'data.frame':  143 obs. of  3 variables:
## ..$ node1 : chr [1:143] "B Karoń" "G Kulczycki" "B Karoń" "G Kulczycki" ...
## ..$ node2 : chr [1:143] "A Bartmański" "A Bartmański" "A Bartmański" "A Bartmański" ...
## ..$ weight: num [1:143] 0.333 0.333 0.333 0.333 0.45 ...

plotNetwork(d$nodes, d$edges, file="network.html")
# cleaning network data
network <- graph_from_data_frame(d$edges, directed=FALSE)
set.seed(123)
l <- layout_fruchterman_reingold(network, niter=50) # layout
fc <- walktrap_community(network) # community detection
# node locations
nodes <- data.frame(l); names(nodes) <- c("x", "y")
nodes$cluster <- factor(fc$membership)
nodes$label <- fc$names
nodes$degree <- degree(network)
# edge locations
edgelist <- get_edgelist(network, names=FALSE)
edges <- data.frame(nodes[edgelist[,1],c("x", "y")], nodes[edgelist[,2],c("x", "y")])
names(edges) <- c("x1", "y1", "x2", "y2")
# and now visualizing it...
p <- ggplot(nodes, aes(x=x, y=y, color=cluster, label=label, size=degree))
pq <- p + geom_text(color="black", aes(label=label, size=degree),
                  show_guide=FALSE) +
  # nodes
  geom_point(color="grey20", aes(fill=cluster),
            shape=21, show_guide=FALSE, alpha=1/2) +

```


```

# edges
geom_segment(
  aes(x=x1, y=y1, xend=x2, yend=y2, label=NA),
  data=edges, size=0.5, color="grey20", alpha=0.1) +
## note that here I add a border to the points
scale_fill_discrete(labels=labels) +
scale_size_continuous(range = c(3, 6)) +
ggtitle("Sieć współautorstwa Grzegorza Kulczyckiego") +
theme(
  plot.title = element_text(size = 14, color = "blue", face = "bold", hjust = 0.5),
  panel.background = element_rect(fill = "white"),
  plot.background = element_rect(fill="white"),
  axis.line = element_blank(), axis.text = element_blank(),
  axis.ticks = element_blank(),
  axis.title = element_blank(), panel.border = element_blank(),
  panel.grid.major = element_blank(),
  panel.grid.minor = element_blank(),
  legend.background = element_rect(colour = F, fill = "black"),
  legend.key = element_rect(fill = "black", colour = F),
  legend.title = element_text(color="white"),
  legend.text = element_text(color="white")
) +
guides(fill = guide_legend(override.aes = list(size=4)))

```

pq

Siec współautorstwa Grzegorza Kulczyckiego




4.1.3 Porównanie sumy cytowań dla publikacji napisanych przez naukowców w kolejnych latach ich pracy

Dla tych samych profili naukowców przeprowadzono także analizę cytowań ich publikacji. Wyznaczone krzywe na podstawie ilości cytowań wskazują na różnicę w ilości cytowań w latach dla tych naukowców.

```
library(scholar)
library(tidyverse)
library(ggplot2)
# id użytkowników
ids <- c("RNDE9-wAAAAJ&hl", "jkj3pCQAAAAJ&hl",
         "L6MYKCQAAAAJ&hl", "umOTaCEAAAAJ")
#utworzenie ramki danych
df <- compare_scholars(ids)
#usunięcie brakujących danych
df <- na.omit(df)
```

```
# wizualizacja ilości cytowań
p <- ggplot(df, aes(x=year, y=total, group = name)) +
  geom_line(aes(colour = name)) +
  scale_fill_brewer(palette = "BrBG")+
  geom_text(aes(label=total), size = 4, check_overlap = TRUE)+
  labs(y="Ilość cytowań")+
  labs(x="Lata")+
  theme_bw() +
  theme(plot.title = element_text(size=14, hjust = 0.5),
        legend.position="top",
        legend.title = element_text(colour="black", size=8, face="bold"),
        legend.text = element_text(colour="black", size=8,face="bold"),
        axis.text.x = element_text(face="bold", color="#993333", size=14),
        axis.title.x = element_text(size = 12),
        axis.text.y = element_text(size = 12),
        axis.title.y = element_text(size = 12))
p + guides(size = FALSE)
```



4.1.4 Dynamika rozwoju publikacyjnego wybranych naukowców na podstawie ilości skumulowanych cytowań w zależności od długości stażu pracy.


Na podstawie otrzymanego wykresu, uwidacznia się inna dynamika cytowań dla młodych naukowców w porównaniu z pracownikami z dłuższym stażem. Wynikać to może z obecnego systemu ewaluacji, w którym młodzi naukowcy obecnie publikują prawie wyłącznie w języku angielskim w indeksowanych czasopismach dostępnych dla szerszego grona społeczności akademickiej.

```
library(scholar)
library(plyr)
library(ggplot2)

ids <- c("RNDE9-wAAAAJ&hl", "jkj3pCQAAAAJ&hl", "L6MYKCQAAAAJ&hl", "um0TaCEAAAAJ")
df_3 <- compare_scholar_careers(ids)
```

```
## Add cumulative citation
df_3 <- ddply(.data = df_3,
              .variables = c("id"),
              .fun = transform,
              cumulative_cites = cumsum(cites))

## Plot
p <- ggplot(df_3, aes(x = career_year, y = cumulative_cites)) +
  geom_line(aes(colour = name)) +
  scale_fill_brewer(palette = "BrBG") +
  geom_text(aes(label=cumulative_cites), size=4, check_overlap = TRUE) +
  labs(y="Skumulowane cytowania") +
  labs(x="Lata pracy") +
  theme_bw() +
  theme(plot.title = element_text(size=14, hjust = 0.5),
        legend.position="top",
        legend.title = element_text(colour="black", size=8, face="bold"),
        legend.text = element_text(colour="black", size=8, face="bold"),
        axis.text.x = element_text(face="bold", color="#993333", size=14),
        axis.title.x = element_text(size = 12),
        axis.text.y = element_text(size = 12),
        axis.title.y = element_text(size = 12))
p + guides(size = FALSE)
```

4.1.5 Metoda web scraping (GS)

Metody te nie są dozwolone na tej bazie danych, ale dla celów dydaktycznych w projekcie wykorzystano bibliotekę [BeautifulSoup](#) do uzyskania tytułów publikacji i linków dla profilu własnego (id = RNDE9-wAAAAJ) w GS. Moduł BeautifulSoup wykorzystuje się do parsowania i przeszukiwania dokumentów HTML.

```
import pandas as pd
import requests
from bs4 import BeautifulSoup as bs

pd.set_option('display.max_columns', None)
pd.set_option('display.max_colwidth', 65)
big_df = pd.DataFrame()
headers = {
    'accept-language': 'en-US,en;q=0.9,pl-PL',
    'x-requested-with': 'XHR',
```

```

        'User-Agent': ('Mozilla/5.0 (Windows NT 10.0; Win64; x64) '
                       'AppleWebKit/537.36 (KHTML, like Gecko) '
                       'Chrome/105.0.0.0 Safari/537.36'))}

s = requests.Session()
s.headers.update(headers)
payload = {'json': '1'}
x = 0
while True:
    url = (
        f'https://scholar.google.com/citations?hl=en&user=RNDE9-wAAAAJ&'
        f'cstart={x}&pagesize=100')
    r = s.post(url, data=payload)
    soup = bs(r.json()['B'], 'html.parser')
    works = [(x.get_text(), 'https://scholar.google.com' + x.get('href'))
              for x in soup.select('a') if 'javascript:void(0)' not in x.get('href')
              and len(x.get_text()) > 7]

    if not works:
        break

    df = pd.DataFrame(works, columns=['Paper', 'Link'])
    big_df = pd.concat([big_df, df], axis=0, ignore_index=True)
    x += 100

csv_file_path = 'output.csv'
big_df.to_csv(csv_file_path, index=False, encoding='utf-8')

limited_df = big_df.head(10)
print(limited_df)

```

```


##                                                                 Paper \
## 0 The effect of elemental sulfur fertilization on plant yields ...
## 1 The Effect of Various Types of Biochar Mixed with Mineral Fer...
## 2 Maize and wheat response to drought stress under varied sulph...
## 3                               Content of selenium in arable soils near Wroclaw
## 4 Sulfur application alleviates chromium stress in maize and wheat
## 5 Wpływ terminu siewu przewodkowych odmian pszenicy uprawianych...

```

```
## 6 Wplyw nawożenia siarka elementarna na zawartosc mikroelemento...
## 7 Towards circular economy: Sustainable soil additives from nat...
## 8 Zawartosc mikroelementow w ziarnie i sromie wybranych odmian ...
## 9 Wplyw nawożenia siarką elementarną na plon i skład chemiczny ...
##
##
## 0 https://scholar.google.com/citations?view_op=view_citation&hl...
## 1 https://scholar.google.com/citations?view_op=view_citation&hl...
## 2 https://scholar.google.com/citations?view_op=view_citation&hl...
## 3 https://scholar.google.com/citations?view_op=view_citation&hl...
## 4 https://scholar.google.com/citations?view_op=view_citation&hl...
## 5 https://scholar.google.com/citations?view_op=view_citation&hl...
## 6 https://scholar.google.com/citations?view_op=view_citation&hl...
## 7 https://scholar.google.com/citations?view_op=view_citation&hl...
## 8 https://scholar.google.com/citations?view_op=view_citation&hl...
## 9 https://scholar.google.com/citations?view_op=view_citation&hl...
```

Link

Wynik wyszukiwania zapisywany jest do pliku csv (rys. 4.3), dane z tego pliku można wykorzystać do dalszych analiz i wizualizacji.



	A	B	C	D	E	F	G
1	Paper	Link					
2	The effect of elemental sulfur fertilization on plant yields and soil properties	https://scholar.google.com/citations?view_op=view_citation&hl...					
3	The Effect of Various Types of Biochar Mixed with Mineral Fertilization on the Development and Ionome of Winter Wheat (Tritic...	https://scholar.google.com/citations?view_op=view_citation&hl...					
4	Maize and wheat response to drought stress under varied sulphur fertilisation	https://scholar.google.com/citations?view_op=view_citation&hl...					
5	Sulfur application alleviates chromium stress in maize and wheat	https://scholar.google.com/citations?view_op=view_citation&hl...					
6	Content of selenium in arable soils near Wrocław	https://scholar.google.com/citations?view_op=view_citation&hl...					
7	Wpływ terminu siewu przewłokowych odmian pszenicy uprawianych na glebie pyłowo-ilastej na plon i parametry morfologiczne	https://scholar.google.com/citations?view_op=view_citation&hl...					
8	Wpływ nawożenia siarką elementarną na plon i skład chemiczny roślin oraz właściwości chemiczne gleby	https://scholar.google.com/citations?view_op=view_citation&hl...					
9	The effect of phosphorus and potassium precision fertilization upon changes in the content of the soluble form of these element...	https://scholar.google.com/citations?view_op=view_citation&hl...					
10	Wpływ nawożenia siarką elementarną na zawartość mikroelementów w roślinach i glebach. Cz. II. Mangan i żelazo	https://scholar.google.com/citations?view_op=view_citation&hl...					
11	Zawartość mikroelementów w ziarnie i słomie wybranych odmian pszenicy ozimej	https://scholar.google.com/citations?view_op=view_citation&hl...					
12	Zawartość siarki ogólniej i siarczanowej w glebach Polski Południowo-Zachodniej	https://scholar.google.com/citations?view_op=view_citation&hl...					
13	Towards circular economy: Sustainable soil additives from natural waste fibres to improve water retention and soil fertility	https://scholar.google.com/citations?view_op=view_citation&hl...					
14	Skład chemiczny roślin uprawnych na terenach oddziaływania hut miedzi. Cz. II-Miedź i ołów	https://scholar.google.com/citations?view_op=view_citation&hl...					
15	Modification of Butters-Chenery method for determination of total sulfur in plants and soil	https://scholar.google.com/citations?view_op=view_citation&hl...					
16	Wpływ siarki siarczanowej i elementarnej na plon i skład chemiczny roślin oraz właściwości chemiczne gleby	https://scholar.google.com/citations?view_op=view_citation&hl...					
17	The content of microelements in grain and straw of selected winter wheat cultivars	https://scholar.google.com/citations?view_op=view_citation&hl...					
18	Wpływ oddziaływania wybranych związków przemysłowych na zawartość siarki w glebie i roślinach	https://scholar.google.com/citations?view_op=view_citation&hl...					
19	Wpływ oddziaływania wybranych związków przemysłowych na zawartość metali ciężkich w glebach i roślinach	https://scholar.google.com/citations?view_op=view_citation&hl...					
20	Wpływ zroczowanego nawożenia potasem na wybrane właściwości gleby oraz plon i pobieranie składników pokarmowych przez	https://scholar.google.com/citations?view_op=view_citation&hl...					
21	The effect of soil and foliar sulphur application on winter wheat yield and soil properties	https://scholar.google.com/citations?view_op=view_citation&hl...					
22	The effect of foliar applied fertilizer ekolist on the yield and chemical composition of spring wheat.	https://scholar.google.com/citations?view_op=view_citation&hl...					
23	The effect of sowing date of facultative wheat varieties cultivated on silt-loam soil on yield and plant morphology.	https://scholar.google.com/citations?view_op=view_citation&hl...					

Rysunek 4.3: Zestawienie publikacji i linków dla wybranego id naukowca

Z otrzymanego pliku csv wyodrębniono tytuły publikacji jako plik txt w celu wykonania chmury wyrazów.

4.1.6 Utworzenie oddzielnych plików z tytułami w języku angielskim i polskim

Ponieważ w pliku znajdują się tytuły w języku angielskim i polskim, wykorzystano bibliotekę [langdetect 1.0.9](#) do stworzenia oddzielnych plików z tytułami w języku angielskim i polskim.

```
from langdetect import detect
import pandas as pd

# Odczytaj plik i przeczytaj tytuły artykułów
with open('siarka.txt', 'r', encoding='utf-8') as file:
    article_titles = file.readlines()

# Inicjalizacja list na tytuły po angielsku i po polsku
english_titles = []
polish_titles = []

# Podział tytułów na dwa zestawy bazując na wykrytym języku
for title in article_titles:
    if detect(title) == 'en':
        english_titles.append(title)
    elif detect(title) == 'pl':
        polish_titles.append(title)

# Zapisz tytuły artykułów po angielsku do pliku
with open('english_titles.txt', 'w', encoding='utf-8') as file:
    file.writelines(english_titles)

# Zapisz tytuły artykułów po polsku do pliku
with open('polish_titles.txt', 'w', encoding='utf-8') as file:
    file.writelines(polish_titles)
```

Pliki te wykorzystano do stworzenia chmur wyrazów w języku angielskim i polskim za pomocą biblioteki [wordcloud](#).

4.1.7 Utworzenie chmury wyrazów w języku angielskim:

```
library(tm)
#library(SnowballC)
library(wordcloud)
library(RColorBrewer)

filePath <- "english_titles.txt"
text <- readLines(filePath)
docs <- Corpus(VectorSource(text))
toSpace <- content_transformer(function (x , pattern ) gsub(pattern, " ", x))
docs <- tm_map(docs, toSpace, "/")
docs <- tm_map(docs, toSpace, "@")
docs <- tm_map(docs, toSpace, "\\|")
docs <- tm_map(docs, content_transformer(tolower))
docs <- tm_map(docs, removeNumbers)
docs <- tm_map(docs, removeWords, stopwords("english"))
docs <- tm_map(docs, removeWords, c("blabla1", "blabla2"))
docs <- tm_map(docs, removePunctuation)
docs <- tm_map(docs, stripWhitespace)
dtm <- TermDocumentMatrix(docs)
m <- as.matrix(dtm)
v <- sort(rowSums(m),decreasing=TRUE)
d <- data.frame(word = names(v),freq=v)
head(d, 10)
```

##	word	freq
## soil	soil	20
## effect	effect	19
## content	content	17
## wheat	wheat	15
## plants	plants	15

[illegible]

```
library(tm)
library(SnowballC)
library(wordcloud)
library(RColorBrewer)
```

```

filePath <- "polish_titles.txt"
text <- readLines(filePath)
docs <- Corpus(VectorSource(text))
toSpace <- content_transformer(function (x , pattern ) gsub(pattern, " ", x))
docs <- tm_map(docs, toSpace, "/")
docs <- tm_map(docs, toSpace, "@")
docs <- tm_map(docs, toSpace, "\\|")
docs <- tm_map(docs, content_transformer(tolower))
docs <- tm_map(docs, removeNumbers)
docs <- tm_map(docs, removeWords, stopwords("english"))
docs <- tm_map(docs, removeWords, c("blabla1", "blabla2"))
docs <- tm_map(docs, removePunctuation)
docs <- tm_map(docs, stripWhitespace)
dtm <- TermDocumentMatrix(docs)
m <- as.matrix(dtm)
v <- sort(rowSums(m),decreasing=TRUE)
d <- data.frame(word = names(v),freq=v)
head(d, 10)

```

```

##                word freq
## zawartosc      zawartosc  10
## glebach        glebach   6
## mikroelementow mikroelementow  5
## roslinach      roslinach  5
## nawozenia      nawozenia  4
## wplyw          wplyw     4
## odmian         odmian    4
## ozimej         ozimej     4
## pszenicy       pszenicy   4
## wybranych     wybranych   4

```

```

set.seed(1234)
wordcloud(words = d$word, freq = d$freq, min.freq = 1,
          max.words=200, random.order=FALSE, rot.per=0.35,
          colors=brewer.pal(8, "Dark2"))

```


- **Rekomendacje:** Zawiera rekomendowane artykuły podobne do danego artykułu.
- **Datasets:** Udostępnia linki do pobrania zbiorów danych na wykresie akademickim.
- **Conference Peer Review:** Zapewnia narzędzia pomagające organizatorom konferencji z problemem przypisywania recenzentów do zgłoszeń konferencyjnych. Obejmuje wykrywanie konfliktu interesów w oparciu o relacje między współautorami oraz obliczanie wyniku dopasowania między recenzentem a tematem zgłoszenia w oparciu o historię publikacji recenzenta.

Użytkownik bazy Semantic Scholar może złożyć wniosek o przyznanie klucza API, dzięki czemu uzyskuje następujące parametry połączenia:

- Limit szybkości: - 1 żądanie na sekundę dla następujących punktów końcowych:

/paper/batch

/paper/search

/rekomendacje

- 10 żądań na sekundę dla wszystkich innych połączeń

Dostęp do dużych ilości danych za pośrednictwem interfejsów API jest istotny ze względu na przeprowadzenie lepszych i głębszych analiz, które mogą wydobyć ukrytą wiedzę i znaleźć nowe wzorce zachowań (Velez-Estevez i in., 2023)

Poniżej przedstawiono możliwości przeszukiwania bazy danych Semantic Scholar:

4.2.1 Wyszukanie nazwisk autorów publikacji poprzez id ich profili z wykorzystaniem biblioteki [semanticscholar 0.7.0](#).

```
from semanticscholar import SemanticScholar

sch = SemanticScholar()
list_of_author_ids = ['113275711', '12961311', '87266064', '113633308']
results = sch.get_authors(list_of_author_ids)
print("Użytkownicy bazy Semantic Scholar:")
```

Użytkownicy bazy Semantic Scholar:

```
for item in results:
    print(item.name)
```

```
## G. Kulczycki
## S. Pietr
## E. Sacała
## M. Samoraj
```

4.2.2 Przeszukiwanie bazy poprzez frazę słów z wykorzystaniem biblioteki [semanticscholar 0.7.0](#).

```
from semanticscholar import SemanticScholar

sch = SemanticScholar()
results = sch.search_paper('elemental sulphur fertilization')
counter = 1
print("Wyniki wyszukiwania 10 pierwszych rekordów: ")
```

```
## Wyniki wyszukiwania 10 pierwszych rekordów:
```

```
for index, item in enumerate(results):
    # Print the number and title of the paper
    print(f"{index+1}. {item.title}")
    counter += 1
    if counter > 10:
        break
```

```
## 1. Improving nutritional status, yield and fruit quality of Barhi Date palm cultivar
## 2. Effect of combined fertilization with rock phosphate and elemental sulphur on yi
## 3. Sulphur fertilization on biochemical constituents of cabbage (Brassica oleracea
## 4. THE EFFECT OF ELEMENTAL SULFUR FERTILIZATION ON GREEN BEANS ( Phaseolus Vulgaris
## 5. Effect of Sulphur Fertilization on Amino Acid and Fraction Composition of Protei
## 6. Influence of sulphur fertilization on nutrient uptake of onion (Allium cepa L.)
## 7. EFFECT OF SULPHUR FERTILIZATION ON GROWTH, YIELD AND NUTRIENT UPTAKE OF SUNFLOWE
## 8. EFFECT OF SULPHUR FERTILIZATION ON GROWTH , YIELD AND QUALITY OF SESAME ( SESAMU
## 9. Influence of planting dates and sulphur fertilization on physical and chemical t
```

10. DOES THE SULPHUR FERTILIZATION MODIFY MAGNESIUM AND CALCIUM CONTENT IN POTATO T

4.2.3 Przeszukiwanie bazy danych z wykorzystaniem [ChatOpenAI](#) z pomocą [Semantic Scholar API Tool](#)

Na rysunku 4.4 przedstawiono skrypt wykorzystujący ChatGPT do przeszukiwania i uzyskiwania odpowiedzi na zadawane pytania z bazy Semantic Scholar. W skrypcie zastosowano własny klucz API wygenerowany na stronie [OpenAI](#).

```
from langchain import hub
from langchain.agents import AgentExecutor, create_openai_functions_agent
from langchain_openai import ChatOpenAI

instructions = """You are an expert researcher."""
base_prompt = hub.pull("langchain-ai/openai-functions-template")
prompt = base_prompt.partial(instructions=instructions)

llm = ChatOpenAI(openai_api_key="sk-40UT3B1bkFJoVIsDgeW16qu6eyNWXEy", temperature=0)

from langchain_community.tools.semanticscholar.tool import SemanticScholarQueryRun
tools = [SemanticScholarQueryRun()]
agent = create_openai_functions_agent(llm, tools, prompt)

agent_executor = AgentExecutor(
    agent=agent,
    tools=tools,
    verbose=True,
)

agent_executor.invoke(
    {
        "input": "How elemental sulphur fertilisation affects crop yields? "
        "show me a list of papers and techniques. Based on your findings write new research questions "
        "to work on. Break down the task into subtasks for search. Use the search tool"}
    )
```

Rysunek 4.4: Skrypt Semantic Scholar API Tool

Przykład uzyskanych wyników dla zadawanych pytań poprzez skrypt Semantic Scholar API Tool rys. 4.5

List of Papers on Elemental Sulphur Fertilisation and Crop Yields:

1. **Title:** Maize and Wheat Response to Drought Stress under Varied Sulphur Fertilisation
- **Authors:** G. Kulczycki, E. Sacała, P. Chohura, Justyna Załuska
- **Published Year:** 2022
2. **Title:** Improving Micronutrient Density in Basmati Rice and Durum Wheat through Summer Green Manuring and Elemental Sulfur Fertilisation
- **Authors:** S. Mandi, Y. S. Shivay, R. Prasanna, Pooniya, Somanath Nayak, Obaidullah Raihan, Kirttiranjan Baral, M. Pal
- **Published Year:** 2022
3. **Title:** Effect of Contamination with Sulphur on Soil Properties and Crop Yields in a Lysimetric Experiment. I. Effect of Elemental Sulphur on the Chemical Properties of Soils
- **Authors:** T. M. Terelak, J. Gador
- **Published Year:** 1986
4. **Title:** Nitrogen and Sulphur Fertilisation Affecting Soybean Seed Spermidine Content
- **Authors:** J. Antonkiewicz, T. Lošák, Michael C. Sevcik, R. Plchova, E. Álvarez, J. Elbl
- **Published Year:** 2018

Research Questions:

1. How does elemental sulphur fertilisation impact the micronutrient composition and yield of different crop varieties under varying levels of water stress?
2. What are the optimal application rates of elemental sulphur for enhancing micronutrient density in staple crops like rice and wheat?
3. How does the combination of green manuring and elemental sulphur fertilisation affect the bioavailability of micronutrients in crops and their subsequent impact on human nutrition?
4. What are the long-term effects of elemental sulphur fertilisation on soil properties, crop yields, and sustainability of agricultural systems?
5. How can elemental sulphur fertilisation be integrated into precision agriculture practices to maximize crop yields while minimizing environmental impacts?

Subtasks for Further Research:

1. Conduct a meta-analysis of existing studies on elemental sulphur fertilisation to identify common trends and knowledge gaps.
2. Investigate the mechanisms by which elemental sulphur influences micronutrient uptake and plant growth in different crop species.
3. Explore the interactions between elemental sulphur fertilisation, soil microbiota, and nutrient cycling in agroecosystems.
4. Assess the economic feasibility and practical implications of implementing elemental sulphur fertilisation strategies in smallholder farming systems.
5. Collaborate with agronomists and farmers to conduct field trials and demonstrations to validate the efficacy of elemental sulphur fertilisation in real-world agricultural settings.

Rysunek 4.5: Wynik zastosowania skryptu wykorzystujący ChatGPT

5 Wnioski

Na podstawie przeprowadzonych analiz wyciągnięto następujące wnioski:

1. Narzędzia data science w znacząco usprawniają przegląd literatury w obu analizowanych bazach indeksujących w porównaniu do tradycyjnych metod ich przeszukiwania.
2. Metody data science szczególnie pomocne są przy analizowaniu danych z tych baz w szerszej skali (np. analiza porównawcza bibliometryczna dorobku kilkunastu użytkowników lub porównanie siły oddziaływania czasopism z określonego obszaru badawczego).
3. Wykorzystania kilku narzędzi data science (np. języki Python, R, ChatGPT) do przeglądu bibliometrycznego umożliwia uzyskanie niestandardowych efektów takiej pracy.
4. Intensywny rozwój metod data science będzie się przyczyniać do powstawania coraz bardziej efektywnych metod wykonywania przeglądów bibliometrycznych.

6 Literatura

- Apanowicz, J. 2005. Metodologiczne uwarunkowania pracy naukowej. Prace doktorskie. Prace habilitacyjne. Difin, Warszawa.
- Chigbu, U.E., S.O. Atiku, i C.C. Du Plessis. 2023. The Science of Literature Reviews: Searching, Identifying, Selecting, and Synthesising. *Publications* 11(11): 2. doi: [10.3390/publications11010002](https://doi.org/10.3390/publications11010002).
- Comarch. 2023. Ranking najpopularniejszych języków programowania według TIOBE Index. <https://kariera.comarch.pl/blog/python-na-czele-julia-pierwszy-raz-w-czolowej-dwudziestce-ranking-najpopularniejszych-jezykow-programowania-wedlug-tiobe-index/>.
- Cooper, H.M. 1986. The integrative research review: a systematic approach. 2. print. Sage.
- Curcic, D. 2023. Number of academic papers published per year. WordsRated.
- Dz. U. 2019. Rozporządzenie Ministra Nauki i Szkolnictwa Wyższego z dnia 22 lutego 2019 r. w sprawie ewaluacji jakości działalności naukowej Poz. 392.
- Górecki, T. 2011. Podstawy statystyki z przykładami w R. Wydawnictwo BTC, Legionowo.
- Kinney, R., C. Anastasiades, R. Authur, I. Beltagy, J. Bragg, i in. 2023. The Semantic Scholar Open Data Platform. doi: [10.48550/ARXIV.2301.10140](https://doi.org/10.48550/ARXIV.2301.10140).
- PBN. 2020. Słownik pojęć Polska Bibliografia Naukowa. Polska Bibliografia Naukowa. <https://pbn.nauka.gov.pl/centrum-pomocy/baza-wiedzy/slowniczek-pojec/>.
- PWN. 2023. PWN Nauka.
- Struś, A. 2017. R Markdown Narzędzie Do Tworzenia Dynamicznych Dokumentów i Zestawień.
- Tranfield, D., D. Denyer, i P. Smart. 2003. Towards a Methodology for Developing Evidence-Informed Management Knowledge by Means of Systematic Review. *British Journal of Management* 14(3): 207–222. doi: [10.1111/1467-8551.00375](https://doi.org/10.1111/1467-8551.00375).
- Velez-Estevez, A., I.J. Perez, P. García-Sánchez, J.A. Moral-Munoz, i M.J. Cobo. 2023. New trends in bibliometric APIs: A comparative analysis. *Information Processing & Management* 60(4): 103385. doi: [10.1016/j.ipm.2023.103385](https://doi.org/10.1016/j.ipm.2023.103385).
- Wickham, H., i G. Grolemund. 2018. Język R. Kompletny zestaw narzędzi dla analityków danych. Helion, Gliwice.
- Ziemkiewicz, B., i J. Karłowska-Pik. 2013. LATEX dla matematyków. Wydawnictwo Naukowe UMK Toruń.